

Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών



Εργασία στο μάθημα *Θεωρία Εκτίμησης και Ανίχνευσης*

Διδάσκων: Πετραντωνάκης Παναγιώτης

Ομάδα 9

Τουτζίαρης Γεώργιος AEM 10568

Χυτίρογλου Μιχαήλ AEM 10475

Θέμα 1°:

1° Ερώτημα:

Το ζητούμενο κατώτατο όριο της διασποράς για την εκτίμηση της παραμέτρου λ πρόκειται για το Cramer Rao Lower Bound ή CRLB. Για την εκθετική κατανομή η συνάρτηση πυκνότητας πιθανότητας (pdf) είναι της μορφής:

$$p(x; \lambda) = \begin{cases} \lambda \exp(-\lambda x), & x > 0 \\ 0, & \text{αλλιώς} \end{cases}$$

ενώ για δείγμα n θετικών ανεξάρτητων παρατηρήσεων $X = \{x_1, x_2, \dots, x_n\}$ που ακολουθούν εκθετική κατανομή, η συνάρτηση πιθανοφάνειας ισούται με το γινόμενο των pdf των επιμέρους παρατηρήσεων, είναι δηλαδή ίση με:

$$L(\lambda) = \prod_{i=1}^n \lambda \exp(-\lambda x_i)$$

Ο λογάριθμος της $L(\lambda)$ (λογαριθμική συνάρτηση πιθανοφάνειας ή συνάρτηση log-likelihood) είναι:

$$\log L(\lambda) = \sum_{i=1}^n \log(\lambda \exp(-\lambda x_i))$$

ή ισοδύναμα:

$$\log L(\lambda) = n \log(\lambda) - \lambda \sum_{i=1}^n x_i$$

Η παράγωγος της log-likelihood ως προς λ θα είναι επομένως ίση με:

$$\frac{\partial \log L(\lambda)}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i$$

Θα αποδείξουμε παρακάτω την ισχύ του regularity condition, που αποτελεί προϋπόθεση για την ύπαρξη του CRLB:

Η pdf της εκθετικής κατανομής είναι συνεχής και δις παραγωγίσιμη ως προς λ . Ακόμη, για την αναμενόμενη τιμή της πρώτης παραγώγου log-likelihood ισχύει:

$$E \left[\frac{\partial \log L(\lambda)}{\partial \lambda} \right] = E \left[\frac{n}{\lambda} \right] - E \left[\sum_{i=1}^n x_i \right]$$

Τα n, λ δεν είναι τυχαίες μεταβλητές, αλλά σταθερές, και η αναμενόμενη τιμή για κάθε παρατήρηση της εκθετικής κατανομής ισούται με τον αντίστροφο της παραμέτρου λ . Έχουμε άρα:

$$E \left[\frac{n}{\lambda} \right] = \frac{n}{\lambda}$$

$$E \left[\sum_{i=1}^n x_i \right] = \sum_{i=1}^n E[x_i] = \sum_{i=1}^n \frac{1}{\lambda} = \frac{n}{\lambda}$$

και επομένως θα ισχύει:

$$E \left[\frac{\partial \log L(\lambda)}{\partial \lambda} \right] = \frac{n}{\lambda} - \frac{n}{\lambda} = 0$$

Αποδείχτηκε η ισχύς του regularity condition. Για να υπολογίσουμε το CRLB, θα αναζητήσουμε πρώτα τη δεύτερη παράγωγο της log-likelihood:

$$\frac{\partial^2 \log L(\lambda)}{\partial \lambda^2} = -\frac{n}{\lambda^2}$$


και εν συνεχεία την πληροφορία Fisher:

$$I(\lambda) = -E \left[\frac{\partial^2 \log L(\lambda)}{\partial \lambda^2} \right] = \frac{n}{\lambda^2}$$

Συνεπώς, το κατώτατο όριο της διασποράς για την εκτίμηση του λ είναι ίσο:

$$\text{Var}[\lambda_{\text{hat}}] \geq \frac{1}{I(\lambda)} = \frac{\lambda^2}{n} \text{ (CRLB)}$$

Στο MATLAB τρέχουμε 5000 πειράματα στα οποία δημιουργούμε δείγματα 10 παρατηρήσεων και σε κάθε πείραμα για το λ , εκτιμούμε έναν Αμερόληπτο Εκτιμητή που επιτυγχάνει το CRLB, δηλαδή την ελάχιστη δυνατή διασπορά (Minimum Variance Unbiased Estimator ή MVUE). Ο εκτιμητής που θα επιλέξουμε ακολουθεί Gaussian κατανομή με μέση τιμή ίση με την τιμή για το λ (κατά την υπόδειξη της εκφώνησης θεωρήσαμε $\lambda=2$) και τυπική απόκλιση ίση με την τετραγωνική ρίζα του CRLB. Για $\lambda=2$ και $n=10$ μετρήσεις ανά πείραμα, η διασπορά ισούται με $\frac{2^2}{10} = 0.4$. Το ιστόγραμμα για τον MVUE εκτιμητή του λ σε 5000 πειράματα απεικονίζεται παρακάτω:



Από το ιστόγραμμα, είναι φανερό πως ο εκτιμητής ακολουθεί κανονική κατανομή με μέση τιμή πολύ κοντά στο 2 (ίση με 2.006), γεγονός που τον καθιστά αμερόληπτο, και διασπορά κοντά στο κατώτατο όριο των 0.4 (ίση με 0.405), με αποτέλεσμα να είναι και efficient.

2^ο Ερώτημα:

Για τον Εκτιμητή Μέγιστης Πιθανοφάνειας (Maximum Likelihood Estimator ή MLE), για δείγμα n θετικών ανεξάρτητων παρατηρήσεων $X = \{x_1, x_2, \dots, x_n\}$ που ακολουθούν εκθετική κατανομή, η συνάρτηση πιθανοφάνειας είναι:

$$L(\lambda) = \prod_{i=1}^n \lambda \exp(-\lambda x_i)$$

Όπως δείξαμε παραπάνω, η παράγωγος της log-likelihood ως προς λ θα είναι επομένως ίση με:

$$\frac{\partial \log L(\lambda)}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i$$


ενώ για να βρούμε τον εκτιμητή $\lambda_{MLE.EXP}$ θα εξισώσουμε την παραπάνω έκφραση με το 0 και θα λύσουμε ως προς λ , και θα προκύψει:

$$\lambda_{MLE.EXP} = \frac{n}{\sum_{i=1}^n x_i}$$

Για $n=10$ παρατηρήσεις ανά πείραμα, ο εκτιμητής γίνεται ίσος με:

$$\lambda_{MLE.EXP} = \frac{10}{\sum_{i=1}^{10} x_i}$$

Με τη βοήθεια του MATLAB, εκτελούμε 5000 πειράματα με $n=10$ παρατηρήσεις το καθένα, και απεικονίζουμε στην παρακάτω εικόνα το ιστόγραμμα για τους MLE εκτιμητές όλων των πειραμάτων για το λ :




Παρατηρούμε πως σε αντίθεση με το ιστόγραμμα του MVUE, εδώ η μέση τιμή των δεδομένων είναι 2.215 και η διασπορά είναι 0.591, δηλαδή ο MLE δεν φτάνει το CRLB που είναι 0.4. Επομένως, συμπεραίνουμε πως μόλις $n=10$ μετρήσεις ανά πείραμα είναι πολύ μικρό δείγμα, και κατά συνέπεια ο MLE δεν είναι ούτε αμερόληπτος ούτε efficient.

3^ο Ερώτημα:

Εκτελούμε τον κώδικα του MATLAB για υπολογισμό των MVUE και MLE, όπως περιγράψαμε στα ερωτήματα 1 και 2, όμως αυτή τη φορά καθένα από τα πειράματα

έχει δείγματα 20, 50 ή 100 παρατηρήσεων. Στις τρεις παρακάτω εικόνες απεικονίζονται τα ιστογράμματα των αντίστοιχων περιπτώσεων:



Σημειώνουμε πως για 20, 50 και 100 μετρήσεις, το CRLB από τη σχέση που υπολογίσαμε παραπάνω γίνεται ίσο με 0.2, 0.08 και 0.04 αντιστοίχως. Παρατηρούμε πως για οσοδήποτε μεγάλο πλήθος παρατηρήσεων (10, 20, 50, 100) ανά πείραμα, ο MVUE είναι αμερόληπτος, διότι η μέση τιμή του παραμένει το 2, και efficient, διότι η διασπορά του μειώνεται κάθε φορά πλησιάζοντας πολύ κοντά στο εκάστοτε CRLB. Παράλληλα, όσο μεγαλώνει το πλήθος των παρατηρήσεων, τόσο πιο κοντά πλησιάζει η μέση τιμή του MLE στο επιθυμητό 2, και επίσης τόσο περισσότερο ελαττώνεται η διασπορά πλησιάζοντας τη διασπορά του MVUE. Μάλιστα, για $n=50$, τα ιστογράμματα των MVUE και MLE φαίνονται όμοια με λίγο μεγαλύτερη διασπορά για τις τιμές του MLE, ενώ για $n=100$, τα ιστογράμματα μοιάζουν σχεδόν πανομοιότυπα.

Επαληθεύεται επομένως το θεώρημα της ασυμπτωτικής ιδιότητας του MLE, κατά το οποίο για αρκούντως μεγάλο δείγμα δεδομένων, ο MLE προσεγγίζει ασυμπτωτικά την αμεροληψία και το CRLB, είναι δηλαδή και ασυμπτωτικά efficient.

Θέμα 2^ο:

Στο παρόν θέμα καλούμαστε να εκτιμήσουμε την παράμετρο θ του παρακάτω γραμμικού συστήματος μέτρησης:

$$x[n] = h\theta + w[n], n = 0, 1, \dots, N - 1$$

Ερώτημα 1^ο:

Αρχικά θα δοκιμάσουμε να εκτιμήσουμε το θ κάνοντας χρήση του **MMSE (Minimum Mean Square Error)** εκτιμητή, ο οποίος αξιοποιεί μια **εκ των προτέρων συνάρτηση πυκνότητας πιθανότητας** για το θ , προκειμένου να εξάγει έναν εκτιμητή για τα δεδομένα x με παράμετρο το θ . Συγκεκριμένα, ο **MMSE** ισούται με την **μέση τιμή της εκ των υστέρων πιθανότητας** $p(\theta; x)$. Στην προκειμένη περίπτωση, όπου ο εκτιμητής είναι **γραμμικός** ως προς τα δεδομένα, η εύρεση του απλοποιείται στις παρακάτω σχέσεις, οι οποίες πάρθηκαν από τις διαφάνειες του μαθήματος.

$$\begin{aligned} E[\theta|x] &= \mu_\theta + (C_\theta^{-1} + H^T C_w^{-1} H)^{-1} H^T C_w^{-1} (x - H\mu_\theta) \\ C_{\theta|x} &= (C_\theta^{-1} + H^T C_w^{-1} H)^{-1} \end{aligned}$$

Αντικαθιστώντας στην παραπάνω σχέση τα μ_θ , C_θ^{-1} , C_w^{-1} και h , τα οποία στην προκειμένη περίπτωση είναι βαθμωτά μεγέθη και όχι διανύσματα και πίνακες, προκύπτουν τα παρακάτω για τον εκτιμητή και την διασπορά του συναρτήσει των δεδομένων.

$$\hat{\theta} = E[\theta/x] \approx 0.1176x + 3,7647$$

$$C_{\theta/x} \approx 0.9412$$

Ερώτημα 2^ο:

Ακολουθώντας παρόμοια λογική με το **ερώτημα 2** του **θέματος 1**, θα υπολογίσουμε τον **MLE (Maximum Likelihood Estimator)** υπολογίζοντας την pdf για ολόκληρο το διάνυσμα των δεδομένων x , και έπειτα θα βρούμε το θ για το οποίο μεγιστοποιείται η συνάρτηση πιθανοφάνειας:

$$\operatorname{argmax}_\theta [p(x; \theta)]$$

Δεδομένου, και πάλι, ότι ο εκτιμητής είναι **γραμμικός** ως προς το σύστημα μέτρησης, θα αξιοποιήσουμε τις παρακάτω σχέσεις για τον **MLE σε γενικευμένο γραμμικό μοντέλο**, οι οποίες πάρθηκαν από τις διαφάνειες του μαθήματος:

$$\hat{\theta} = \frac{H^T C^{-1} x}{H^T C^{-1} H}$$

$$C_{\hat{\theta}} = (H^T C^{-1} H)^{-1}$$

Όλα τα μεγέθη είναι και πάλι βαθμωτά. Μετά από αντικατάσταση, προκύπτει ο παρακάτω **MLE**:

$$\hat{\theta} = 2x$$


$$C_{\hat{\theta}} = 16$$

Παρατηρούμε πως ο **MMSE** παρουσιάζει πολύ μικρότερη διασπορά από τον **MLE**, το οποίο είναι και αναμενόμενο, καθώς χρησιμοποιεί πρότερη γνώση για την εύρεση του εκτιμητή.


Ερώτημα 3^ο:

Εισάγοντας τους τύπους των 2 αυτών εκτιμητών στο MATLAB, και υπολογίζοντας το **μέσο τετραγωνικό σφάλμα** του εκτιμητή με συνάρτηση αναφοράς την prior κατανομή του θ που επιλέγεται κάθε φορά, ως προς τον **τον αριθμό των δειγμάτων n** και για **διαφορετικές prior κατανομές** προκύπτουν τα εξής αποτελέσματα:


Για **prior κανονική κατανομή N(4,1)** έχουμε:



Για **prior κανονική κατανομή Uniform** με μέση τιμή 4 και διασπορά 16/3 έχουμε:



Για **prior εκθετική κατανομή** με μέση τιμή $1/\lambda = 4$ και διασπορά $1/\lambda^2 = 16$ έχουμε:



Από τα παραπάνω γραφήματα μπορούμε τα εξάγουμε τα εξής συμπεράσματα:

1. Η σύγκλιση του μέσου τετραγωνικού σφάλματος για τον **MMSE** εξαρτάται άμεσα από την έγκυρη επιλογή της *prior* για το θ . Λανθασμένες επιλογές *prior* οδηγούν σε εκτιμητές που χρειάζονται περισσότερες παρατηρήσεις για να συγκλίνουν στον επιθυμητό εκτιμητή.
2. Ο **MMSE**, για μεγάλο αριθμό δειγμάτων, τείνει ασυμπτωτικά να έχει ίδια επίδοση με τον **MLE**. Αυτό συμβαίνει επειδή όσο αυξάνεται το μέγεθος του δείγματος, κατά το Bayesian Central Limit Theory, μειώνεται η συνεισφορά της εκ των προτέρων γνώσης για τον εκτιμητή και ταυτόχρονα αυξάνεται η συνεισφορά της συνάρτησης πιθανοφάνειας. Επομένως και οι δύο εκτιμητές καθορίζονται σχεδόν αποκλειστικά από τη συνάρτηση πιθανοφάνειας και συνεπώς η μεταξύ τους διαφοροποίηση γίνεται αμελητέα.

Θέμα 3°:

Στο παρόν θέμα καλούμαστε να εξετάσουμε από ποια κατανομή προέρχονται τα δεδομένα του αρχείου `data.mat` που συνοδεύει την εκφώνηση της εργασίας. Τα εν λόγω δεδομένα είναι ένα διάνυσμα 1000 δεκαδικών αριθμητικών τιμών. Οι πιθανές επιλογές είναι η κατανομή Rayleigh με συνάρτηση πυκνότητας πιθανότητας (pdf) της μορφής:

$$p(x; \lambda) = \begin{cases} \frac{x}{\lambda^2} \exp\left(-\frac{x^2}{2\lambda^2}\right), & x \geq 0 \\ 0, & \text{αλλιώς} \end{cases}$$

ή εκθετική κατανομή με συνάρτηση πυκνότητας πιθανότητας της μορφής:

$$p(x; \lambda) = \begin{cases} \lambda \exp(-\lambda x), & x > 0 \\ 0, & \text{αλλιώς} \end{cases}$$

Η μέθοδος που ακολουθήσαμε αρχικά απαιτεί την εύρεση του Εκτιμητή Μέγιστης Πιθανοφάνειας (Maximum Likelihood Estimator ή MLE) για την παράμετρο λ των δεδομένων σε δύο περιπτώσεις. Στην πρώτη περίπτωση υποθέτουμε ότι τα δεδομένα ακολουθούν Rayleigh κατανομή και αναζητούμε τον εκτιμητή $\lambda_{\text{MLE.RAY}}$, ενώ στη δεύτερη περίπτωση υποθέτουμε ότι τα δεδομένα ακολουθούν εκθετική κατανομή και αναζητούμε τον εκτιμητή $\lambda_{\text{MLE.EXP}}$. Έπειτα, θα δημιουργήσουμε με τη χρήση MATLAB δύο ψευδοτυχαία δείγματα 1000 παρατηρήσεων για το κάθε δείγμα που ακολουθούν εκθετική και Rayleigh κατανομή χρησιμοποιώντας ως παραμέτρους τους εκτιμητές $\lambda_{\text{MLE.EXP}}$ και $\lambda_{\text{MLE.RAY}}$ αντιστοίχως και θα απεικονίσουμε τα ιστογράμμά τους, καθώς και το ιστόγραμμα των αρχικών δεδομένων του `data.mat`. Τέλος, θα εξετάσουμε ποιου δείγματος το ιστόγραμμα παρουσιάζει μεγαλύτερη ομοιότητα με το ιστόγραμμα των αρχικών δεδομένων και στην περίπτωση που η ομοιότητα αυτή είναι μεγάλη, θα μπορέσουμε να απαντήσουμε στο αρχικό ερώτημα.

Για την περίπτωση της κατανομής Rayleigh, προκειμένου να βρούμε τον MLE εκτιμητή για την παράμετρο λ , θα πρέπει να αναζητήσουμε το λογάριθμο της συνάρτησης πιθανοφάνειας $L(\lambda)$, και στη συνέχεια να λύσουμε ως προς λ την εξίσωση:

$$\frac{\partial \log(L(\lambda))}{\partial \lambda} = 0$$

ώστε σύμφωνα με το θεώρημα ακροτάτων, να εκτιμήσουμε την τιμή της παραμέτρου λ για την οποία η ο λογάριθμος της $L(\lambda)$ (λογαριθμική συνάρτηση πιθανοφάνειας ή συνάρτηση log-likelihood) μεγιστοποιείται. Για δείγμα n ανεξάρτητων παρατηρήσεων $X = \{x_1, x_2, \dots, x_n\}$ που ακολουθούν κατανομή Rayleigh, η συνάρτηση πιθανοφάνειας είναι:

$$L(\lambda) = \prod_{i=1}^n \frac{x_i}{\lambda^2} \exp\left(-\frac{x_i^2}{2\lambda^2}\right)$$

και επομένως, η συνάρτηση log-likelihood είναι:

$$\log L(\lambda) = \log \left(\prod_{i=1}^n \left(\frac{x_i}{\lambda^2} \exp\left(-\frac{x_i^2}{2\lambda^2}\right) \right) \right)$$

ή ισοδύναμα, λόγω της ιδιότητας του λογαρίθμου γινομένου:

$$\log L(\lambda) = \sum_{i=1}^n \log \left(\frac{x_i}{\lambda^2} \exp\left(-\frac{x_i^2}{2\lambda^2}\right) \right)$$

Απλούστερα, γράφουμε:

$$\log L(\lambda) = \sum_{i=1}^n \log \left(\frac{x_i}{\lambda^2} \right) + \sum_{i=1}^n \log \left(\exp\left(-\frac{x_i^2}{2\lambda^2}\right) \right)$$

ή ισοδύναμα:

$$\log L(\lambda) = \sum_{i=1}^n \log(x_i) - 2n \log(\lambda) - \frac{1}{2\lambda^2} \sum_{i=1}^n x_i^2$$

Η παράγωγος της log-likelihood ως προς λ προκύπτει ίση με:

$$\frac{\partial \log L(\lambda)}{\partial \lambda} = -\frac{2n}{\lambda} + \frac{1}{\lambda^3} \sum_{i=1}^n x_i^2$$

και εξισώνοντάς τη με το 0 και πολλαπλασιάζοντας τα 2 μέλη με λ^3 έχουμε:

$$-2n\lambda^2 + \sum_{i=1}^n x_i^2 = 0$$

Τέλος, λύνοντας ως προς λ και δεχόμενοι μόνο τη θετική λύση της εξίσωσης, προκύπτει ο εκτιμητής $\lambda_{MLE.RAY}$ ίσος με:

$$\lambda_{MLE.RAY} = \sqrt{\frac{1}{2n} \sum_{i=1}^n x_i^2}$$

Με παρόμοιο τρόπο, και όπως υπολογίσαμε στο 2^ο ερώτημα του 1^{ου} θέματος για δείγμα n ανεξάρτητων παρατηρήσεων $X = \{x_1, x_2, \dots, x_n\}$ που ακολουθούν εκθετική κατανομή, ο MLE εκτιμητής $\lambda_{MLE.EXP}$ είναι:

$$\lambda_{MLE.EXP} = \frac{n}{\sum_{i=1}^n x_i}$$

Όπως αναφέραμε παραπάνω, χρησιμοποιώντας ως παραμέτρους τους εκτιμητές $\lambda_{MLE.EXP}$ και $\lambda_{MLE.RAY}$, θα δημιουργήσουμε δύο ψευδοτυχαία δείγματα 1000 παρατηρήσεων το καθένα που ακολουθούν εκθετική και Rayleigh κατανομή αντίστοιχα. Εκτυπώνοντας τα ιστογράμματα των τριών κατανομών, παρατηρούμε ότι η pdf των αρχικών δεδομένων εμφανίζει σημαντική ομοιότητα στη μορφή της με την κατανομή Rayleigh, ενώ παράλληλα είναι πολύ διαφορετική από την pdf της εκθετικής κατανομής. Συμπεραίνουμε επομένως ότι τα αρχικά δεδομένα μας ακολουθούν κατανομή Rayleigh.

